

La méthode des moindres carrés ordinaires :

Économétrie : La régression linéaire simple.

Alexis VIALATTE

April 12, 2021

Sommaire

- 1 Introduction à la régression linéaire simple
- 2 Formalisation de la régression linéaire simple

Sujet

Énoncé : En Mondelēzie, dans une école de tricotage de rien ou tricotage de R en langage jeune, l'enseignant M. Favard a demandé à ses étudiants de ne pas consommer de chocolat de la région de la Côte d'Or pour ne pas attraper la maladie de Pacques et risquer de ne pas pouvoir assister à l'examen. A-t-il raison ? Est-ce que la consommation de chocolat de la région de la Côte d'Or augmente le risque d'attraper la maladie de Pacques ? Pour répondre à ces questions, nous disposons la base de données suivante concernant 10 étudiants de Lécot :


i	1	2	3	4	5	6	7	8	9	10
x_i	2	4	6	8	10	2	4	6	8	10
y_i	2.5	6	7.5	10	2.5	1.5	4	4.5	6	9.5

Table: Base de données lecot

Sujet

La base de données contient 10 individus notés i où x_i correspond au nombre de tablettes de chocolat consommées par le i ème individu et y_i correspond au nombre de jours de sommeil causé par la maladie de Pacques pour le i ème individu *A priori*, x_i est la variable explicative et y_i est la variable expliquée.

L'estimation sous la forme d'une droite




L'estimation sous la forme d'une droite

L'équation d'une droite affine est donnée par $y = ax + b$ où a est la pente de la droite y et b est l'ordonnée à l'origine, c'est à dire quand $x = 0$, de la droite y .


$$\begin{cases} A: & 2 = a + b \\ B: & 4 = 3a + b \end{cases} \iff \begin{cases} A: & a = 1 \\ B: & b = 1 \end{cases}$$

$$y = x + 1 \tag{1}$$


L'estimation sous la forme d'une droite




La base de données




La droite supposée \tilde{y}



Les erreurs de la droite supposée \tilde{y}



Les erreurs au carré de la droite supposée \tilde{y}



La méthode des moindres carrés ordinaires

L'équation de la régression linéaire simple est donc $y_i = \alpha + \beta x_i + z_i$
donc l'équation de l'erreur est $z_i = y_i - \alpha - \beta x_i$.

$$\begin{cases} \hat{\alpha} = ? \\ \hat{\beta} = ? \end{cases}$$

La méthode des moindres carrés ordinaires

Nous appliquons la méthode des **MCO** et nous calculons les dérivés de premier ordre en fonction de α et de β :

$$\text{Min} \left(\sum_{i=1}^I z_i^2 \right) = \text{Min} \left[\sum_{i=1}^I (y_i - \alpha - \beta x_i)^2 \right] \quad (2)$$

$$\begin{cases} \frac{\partial \text{MCO}}{\partial \alpha} = 2 \sum_{i=1}^I (y_i - \alpha - \beta x_i) \\ \frac{\partial \text{MCO}}{\partial \beta} = 2 \sum_{i=1}^I x_i (y_i - \bar{y} + \beta \bar{x} - \beta x_i) \end{cases} \iff \begin{cases} \frac{\partial \text{MCO}}{\partial \alpha} = \sum_{i=1}^I y_i - \alpha \sum_{i=1}^I 1 - \beta \sum_{i=1}^I x_i \\ \frac{\partial \text{MCO}}{\partial \beta} = \sum_{i=1}^I x_i y_i - \bar{y} \sum_{i=1}^I x_i + \beta \bar{x} \sum_{i=1}^I x_i - \beta \sum_{i=1}^I x_i^2 \end{cases}$$

$$\begin{cases} \frac{\alpha \sum_{i=1}^I 1}{I} = \frac{\sum_{i=1}^I y_i - \beta \sum_{i=1}^I x_i}{I} \\ \frac{\beta \left(\sum_{i=1}^I x_i^2 - \bar{x} \sum_{i=1}^I x_i \right)}{I} = \frac{\sum_{i=1}^I x_i y_i - \bar{y} \sum_{i=1}^I x_i}{I} \end{cases} \iff \begin{cases} \hat{\alpha} = \frac{1}{I} \sum_{i=1}^I y_i - \hat{\beta} \frac{1}{I} \sum_{i=1}^I x_i \\ \hat{\beta} = \frac{\frac{1}{I} \sum_{i=1}^I (x_i y_i - \bar{y} \bar{x})}{\frac{1}{I} \sum_{i=1}^I (x_i - \bar{x})^2} \end{cases}$$

La méthode des moindres carrés ordinaires

Nous savons que $\bar{y} = \frac{1}{I} \sum_{i=1}^I y_i$, $\bar{x} = \frac{1}{I} \sum_{i=1}^I x_i$, $Cov(x, y) = \frac{1}{I} \sum_{i=1}^I (x_i y_i - \bar{y} \bar{x})$ et $Var(x) = \frac{1}{I} \sum_{i=1}^I (x_i - \bar{x})^2$ donc nous avons :

$$\begin{cases} \hat{\alpha} = \bar{y} - \left(\frac{Cov(x, y)}{Var(x)} \right) \bar{x} \\ \hat{\beta} = \frac{Cov(x, y)}{Var(x)} \end{cases} \quad (3)$$


Calculs

$\bar{x} = 3$, $\bar{y} = 2.7$, $Var(x) = 2.22$ et $Cov(x, y) = 1.22$ donc $\beta = 0.55$ et $\alpha = 1.05$.

Les calculs ont été effectués sur R.

$$y_i = 1.05 + 0.55x_i + z_i \quad (4)$$

La droite \hat{y}



Alors ?

Conclusion : *A priori*, M. Favard a raison.

i	1	2	3	4	5	6	7	8	9	10	$\sum_{i=1}^I z_i^2$
z_i	-0.35	0.85	1.05	1.75	-2.55	-0.85	-0.15	-0.45	-0.25	0.95	13.43

Table: Résidus de la droite \hat{y}

Néanmoins, pour effectuer une régression linéaire décemment, il faudrait tester plusieurs hypothèses :

- Tester l'hypothèse nulle de la constante du modèle (Student),
- Tester l'hypothèse nulle du coefficient du modèle (Student),
- Tester l'hypothèse significative du modèle (Fisher),
- Calculer le R^2 et le R_{ADJ}^2 et les analyser,
- Analyser les résidus et la somme des résidus au carré :
 - Tester la linéarité et l'autocorrélation (Durbin-Watson),
 - Tester la normalité (Shapiro-Wilk),
 - Tester l'homoscédasticité des variances (Harrison-McCabe)...